Aprendizaje por refuerzo con verificación certificada como única recompensa: variantes del PEP bajo V_P

Informe de corrida del proyecto `rl_metodos`

Carlos Manuel Orrego Franco
Universidad Nacional de Colombia, Sede Manizales

Septiembre de 2026 — informe de las corridas `20260924-060113-gpt-6-luna-high` a `20260924-075941-gpt-6-luna-high`

1 Propósito

Esta nota fija el lenguaje común de los subproyectos de `rl_metodos`. Todos comparten una misma estructura: un *proponente* produce un objeto de prueba y un *juez* independiente decide si lo acepta. La recompensa proviene únicamente del juez; el proponente nunca se evalúa a sí mismo. Lo que varía entre subproyectos es el juez, y con él el residuo de confianza que la aceptación deja sin certificar. Esa variación es deliberada: es el experimento.

Este informe agrupa 5 corridas del proponente `gpt-6-luna` (high) bajo V_P, una por objetivo: (1) `pep_gradnorm_n4`, `20260924-060113-gpt-6-luna-high`, terminada; 3 episodios completos; (2) `pep_gradnorm_n6`, `20260924-061836-gpt-6-luna-high`, terminada; 3 episodios completos; (3) `pep_gradnorm_n4_neg`, `20260924-072359-gpt-6-luna-high`, terminada; 3 episodios completos; (4) `pep_fval_mu001_n4`, `20260924-074351-gpt-6-luna-high`, terminada; 3 episodios completos; (5) `pep_fval_mu01_n5`, `20260924-075941-gpt-6-luna-high`, terminada; 3 episodios completos. Presupuesto $B = 4$ intentos por episodio. Memoria entre episodios: sí (`run`). Pregunta que responde: ¿mejora `gpt-6-luna`, con certificado racional exacto, la mejor referencia conocida τ_{ref} en cada instancia?

Este informe sigue la estructura de la nota técnica: el MDP común (§2), la interfaz de verificador y sus tres instancias (§3), las funciones de recompensa (§4), las métricas (§5), la jerarquía de confianza entre jueces (§6) y los entornos (§7, Tabla 5); cierra con los experimentos realizados y previstos (§8), y reporta en §5 los valores medidos.

2 El MDP común

Definición 1 (Entorno de demostración verificada)**.** *Un entorno es una tupla* $\mathcal{E} = (T, \mathcal{A}, V, B)$ *donde* T *es un* objetivo *inmutable (un enunciado y su contexto),* $\mathcal{A}$ *es un espacio de* propuestas*,* V *es un* verificador *y* $B \in \mathbb{N}$ *es un presupuesto de pasos. El MDP asociado es* $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ *con:*

- ***Estado*** $s_t = (T, \mathcal{C}_t, h_t, M_t)$*: el objetivo, el* contexto observable $\mathcal{C}_t$ *que el juez devuelve tras el último intento (lemas disponibles, obligaciones abiertas con su texto literal, o el valor certificado vigente), y el historial* h_t *de resultados anteriores.*
- ***Memoria*** M_t*: resumen del mejor intento de cada episodio anterior (su* τ *frente a* τ_{ref} *y sus pasos). Persiste entre episodios de la corrida. El modelo está congelado: la memoria es contexto, no entrenamiento.*

- ***Acción*** $a_t \in \mathcal{A}$*: una propuesta completa (una cadena de lemas, una anotación de invariantes y variantes, o un programa de tamaños de paso). El proponente es un modelo de lenguaje; la acción es su salida tras una extracción determinista.*
- ***Transición*** $P(s_{t+1} \mid s_t, a_t)$*: determinista dado el juez;* s_{t+1} *incorpora el resultado* $V(T, a_t)$ *y actualiza* $\mathcal{C}_{t+1}$ *y* h_{t+1}*. La estocasticidad del sistema vive en el proponente, no en la transición.*
- ***Recompensa*** $R(s_t, a_t) = r(V(T, a_t))$*, función únicamente del resultado del juez (§4).*
- ***Terminación****: el episodio termina en el primer* t *con resultado* ACCEPTED*, o cuando* $t = B$*.*

Observación 1 (El objetivo es inmutable)**.** *T no forma parte del espacio de acciones. Cualquier propuesta que modifique el enunciado, sus hipótesis o su tipo se rechaza con etiqueta* STATEMENT_DRIFT *(§4.3). Esta restricción se impone en código mediante un hash del enunciado congelado, no por convención. Es la* frontera semántica *del proyecto: el lugar donde la confianza no puede delegarse al juez. En este informe, los hashes de los objetivos son:* `pep_gradnorm_n4: b74aa15da8fa7bcc; pep_gradnorm_n6: 83112c00da746f87; pep_gradnorm_n4_neg: cdda3a2a12ac66fa; pep_fval_mu001_n4: ad5fae0d992a90b3; pep_fval_mu01_n5: 8f8620b97bd07298`*. En* V_P *no existe la etiqueta* STATEMENT_DRIFT*: la instancia* $(n, \mu, criterio)$ *la fija el entorno y la propuesta sólo produce la sucesión de pasos; el hash es el de la etiqueta de la instancia.*

3 La interfaz de verificador y sus tres instancias

Definición 2 (Verificador)**.** *Un verificador es una función* $V : \mathcal{T} \times \mathcal{A} \to \mathcal{O}$ *que devuelve un* resultado

$$o = (\texttt{accepted},\ \texttt{label},\ \texttt{partial},\ \texttt{cost_s},\ \texttt{raw}),$$

con $\texttt{accepted} \in \{0, 1\}$*,* $\texttt{label} \in L$ *y* $\texttt{partial} \in [0, 1]$*, donde* L *es un conjunto finito de etiquetas de resultado propio de cada juez,* `partial` *es una medida de progreso que sólo se usa bajo recompensa moldeada, y* `raw` *es la salida íntegra del juez para auditoría.*

3.1 Juez de grafo de lemas (V_G)

Proviene de los subproyectos 01–05. Un objetivo T es un grafo dirigido acíclico $G = (\Lambda, D)$ de pasos $\lambda \in \Lambda$, cada uno con dependencias $D(\lambda) \subseteq \Lambda$, un subconjunto $\Delta \subset \Lambda$ de *distractores* (pasos falsos o inaplicables, tomados de errores reales de estudiantes) y un paso distinguido QED. Una propuesta es una secuencia $a = (\lambda_1, \ldots, \lambda_k)$ de identificadores anónimos (`L01`, `L02`, ..., barajados con semilla fija); no se muestran los títulos de los pasos ni las refutaciones del profesor, que delatan al distractor. El juez acepta si existe $j \leq k$ con $\lambda_j =$ QED tal que, para todo $i \leq j$,

$$\lambda_i \notin \Delta, \quad \lambda_i \notin \{\lambda_1, \ldots, \lambda_{i-1}\}, \quad D(\lambda_i) \subseteq \{\lambda_1, \ldots, \lambda_{i-1}\};$$

lo que venga después de QED se ignora. Etiquetas, asignadas en el primer paso que falla: ACCEPTED (la cadena llega a QED), INVALID_STEP (dependencia no establecida o paso repetido), DISTRACTOR (el paso es un distractor), UNKNOWN_LEMMA (identificador ajeno al grafo) y INCOMPLETE (todos los pasos son válidos pero la cadena no llega a QED; es un resultado por intento, no por presupuesto). Progreso parcial: fracción del cierre de dependencias de QED establecida antes del primer fallo.

3.2 Juez PEP (V_P)

Proviene del subproyecto 06, que se usa sin modificaciones. El objetivo es una instancia: la clase de funciones L-suaves (μ-fuertemente) convexas con $L = 1$, un horizonte n, un criterio ($f(x_n) - f^*$ o $\|\nabla f(x_n)\|^2$, con $\|x_0 - x^*\| \leq 1$) y si se admiten pasos negativos; una propuesta es un programa `schedule(n)` que genera pasos $(h_0, \ldots, h_{n-1})$. El programa se ejecuta en un intérprete aparte (en macOS, bajo un *sandbox* sin red ni escritura en disco) y el juez puntúa, en un proceso que el programa no tocó, la sucesión literal que devuelve; las referencias se leen una sola vez al empezar. El juez resuelve el problema de estimación de desempeño (PEP) como un programa semidefinido y obtiene el peor caso $\tau(h)$; el certificado dual es la demostración de la cota (Drori and Teboulle, 2014; Taylor et al., 2017). En el modo por defecto, `improve`, toda mejora afirmada se recalcula con tolerancias finas y se certifica en aritmética racional exacta; se acepta sólo si la cota certificada es estrictamente menor que τ_{ref}. La referencia τ_{ref} es el mínimo entre la tabla publicada de óptimos numéricos, que sólo cubre $f(x_n) - f^*$ con $\mu = 0$ (Das Gupta et al., 2024; Grimmer et al., 2024), y la búsqueda propia de 06 por entropía cruzada; en las variantes abiertas (norma del gradiente, fuertemente convexo, pasos negativos) sólo hay búsqueda propia. Etiquetas: CERTIFIED (mejora estricta de τ_{ref} con certificado racional exacto; es la aceptación), MATCHED (sólo en modo `match`: iguala τ_{ref} con tolerancia relativa 10^{-4}, sin certificado exacto), INVALID_SCHEDULE (el programa falla, se agota su tiempo o no devuelve n números finitos válidos), NOT_IMPROVED (programa válido que no mejora τ_{ref}) y CERTIFICATION_FAILED (mejora numérica cuyo certificado exacto falla).

En esta corrida. Instancias: `pep:gradnorm|mu=0|n=4` (modo `improve`, $\tau_{\text{ref}} = 0{,}0169860$, fuente: búsqueda propia de 06 (entropía cruzada); *sandbox*: sí); `pep:gradnorm|mu=0|n=6` (modo `improve`, $\tau_{\text{ref}} = 0{,}0072223$, fuente: búsqueda propia de 06 (entropía cruzada); *sandbox*: sí); `pep:gradnorm|mu=0|n=4|neg` (modo `improve`, $\tau_{\text{ref}} = 0{,}0169860$, fuente: búsqueda propia de 06 (entropía cruzada); *sandbox*: sí); `pep:fval|mu=0.01|n=4` (modo `improve`, $\tau_{\text{ref}} = 0{,}0295431$, fuente: búsqueda propia de 06 (entropía cruzada); *sandbox*: sí); `pep:fval|mu=0.1|n=5` (modo `improve`, $\tau_{\text{ref}} = 0{,}0076055$, fuente: búsqueda propia de 06 (entropía cruzada); *sandbox*: sí).

3.3 Juez Isabelle (V_I)

Proviene del subproyecto 08 y del marco Isabelle/ITrees (Bryant et al., 2026). Un objetivo es un programa imperativo junto con un triple de Hoare de corrección total $H[P]\,C\,[Q]$, ambos congelados; una propuesta es una anotación $a = (inv, var)$ de invariante y variante de bucle y, en fase 2, además lemas auxiliares con su demostración, escritos por el agente y verificados en el kernel antes de usarse. El juez procede por etapas: (0) la anotación pasa una lista blanca de símbolos y el kernel demuestra que el programa anotado es igual al congelado con anotaciones fijas; (0b) si hay lemas, pasan un filtro léxico (sólo enunciados con su demostración: nada de `sorry`, definiciones, notación ni ML) y se compilan en el contexto de las hipótesis, comprobando que el enunciado congelado se lee igual y que no aparecen axiomas nuevos; (1) inserta la anotación y ejecuta el generador de condiciones de verificación `vcg`; (2) intenta cerrar cada obligación con automatización de una línea (`try0` y, si falla, Sledgehammer con tiempo límite fijo), y sólo cuenta una sugerencia de Sledgehammer si su reconstrucción (*preplay*) terminó; (3) si todas cierran, ensambla el teorema completo, lo compila y lo traslada al programa congelado; (4) comprueba que no dependa de oráculos, de `skip_proof` ni de axiomas nuevos. Etiquetas: ACCEPTED (todas las etapas pasan: el teorema está en el kernel), VC_OPEN (alguna obligación sin prueba de una línea), VCG_FAILED (la anotación no se analiza o no tipa, o `vcg` falla), LEMMA_FAILED (el kernel rechaza la demostración de algún lema del agente), ASSEMBLY_FAILED (las obligaciones se cierran por separado pero el teorema ensamblado no compila), UNSOUND (`sorry`, `oops`, oráculos, `skip_proof` o axiomas nuevos), STATEMENT_DRIFT (la propuesta sale de su hueco o el kernel no prueba que el programa anotado sea el congelado), TIMEOUT (se agota el tiempo de compilación) y INVALID_PROPOSAL (falta el invariante o el variante, o hay símbolos o comandos no admitidos). Progreso parcial: fracción de obligaciones cerradas en VC_OPEN y ASSEMBLY_FAILED, y 0 en

las demás.

Observación 2 (Existencia frente a descubrimiento)**.** *Con la anotación del propio artículo (su invariante y su variante), V_I genera 15 obligaciones y la automatización de una línea cierra 9 en esta máquina, con Sledgehammer limitado a 60 s por obligación: VC_Open, 424 s de juez (`runs/_baseline/bisection.json`). Quedan abiertas 4 de variante, 2 de postcondición (clasificación heurística por la conclusión y las premisas de cada obligación). Adelgazar las premisas no basta: sobre una obligación del variante, con todas sus premisas o con una sola, y con o sin los hechos previos de la demostración del artículo, Sledgehammer encuentra prueba en 0 de 4 ensayos de 60 s (`sh_goals.json`). Con la misma anotación y, como lemas del agente, las demostraciones manuales de los autores (los hechos previos, la línea `smt` del variante y `bisect_root_extract`), el juez da Accepted: 15 de 15 obligaciones cerradas, 5 lemas verificados en el kernel, de los que las pruebas de una línea usan `a_less_than_b`, `bisect_root_extract`, `var_dec`; 214 s de juez (`upper_bound.json`). Existe, pues, una demostración que V_I acepta; lo que la automatización no descubre es justamente la parte que los autores escribieron a mano. Por eso V_I distingue tres líneas base: automatización sobre todas las premisas de `vcg`, automatización con un filtro de relevancia estándar, y selección de premisas como acción explícita del agente. Nunca se mezclan. Hoy están implementadas la primera y la acción de lemas auxiliares del agente; el filtro de relevancia y la selección de premisas son trabajo futuro.*

4 Funciones de recompensa

4.1 Recompensa base (todos los jueces)

$$r(o) = \begin{cases} 1 & \text{si } o.\texttt{accepted} = 1, \\ 0 & \text{en otro caso.} \end{cases}$$

Es la única recompensa activa por defecto. Es binaria a propósito: cualquier señal intermedia introduce un juicio sobre qué es "progreso", y ese juicio debe declararse, no esconderse.

4.2 Recompensa moldeada (opcional, tras bandera)

$$r_\beta(o) = r(o) + \beta \cdot o.\texttt{partial} \cdot \mathbb{1}[o.\texttt{accepted} = 0], \qquad \beta \in [0, 0.5].$$

Para V_P se conserva la recompensa original del subproyecto 06, que es continua por naturaleza: $r_P(o) = \max\{-2,\ \log(\tau_{\text{ref}}/\tau(h))\}$ si el programa es válido y -3 en otro caso, donde τ_{ref} es la mejor cota certificada conocida. Se reporta también su binarización $\mathbb{1}[\tau(h) < \tau_{\text{ref}}]$ para hacerla comparable con los otros jueces.

4.3 Penalización por deriva del enunciado

Statement_Drift recibe recompensa 0, no negativa, en la configuración base. La razón es metodológica: queremos *contar* cuántas veces el proponente intenta cambiar la pregunta, y una penalización alteraría la frecuencia que se pretende medir. Una variante con penalización $-\delta$ queda disponible tras bandera para experimentos de control.

En esta corrida: recompensa base binaria $r(o)$; la moldeada está desactivada ($\beta = 0$); penalización de deriva $\delta = 0$ (Statement_Drift recibe 0). La recompensa continua r_P de 06 se registra en cada intento (`raw.reward06`) y sus valores se reportan en §5; no entra en la recompensa del MDP. En el modo `improve` la aceptación es la binarización de r_P con certificado exacto: mejora estricta de τ_{ref} certificada.

5 Métricas

Para cada entorno, juez y proponente se registran:

1. **Intentos hasta aceptación**: mediana y distribución de t^* sobre episodios, con $t^* = B$ si no hay aceptación.

   En esta corrida: (1) t^* mediana 4 sobre 3 episodios completos, censurada en $B = 4$; por episodio: ep. 1: 4 (sin aceptar), ep. 2: 4 (sin aceptar), ep. 3: 4 (sin aceptar); aceptados 0 de 3. (2) t^* mediana 4 sobre 3 episodios completos, censurada en $B = 4$; por episodio: ep. 1: 4 (sin aceptar), ep. 2: 4 (sin aceptar), ep. 3: 4 (sin aceptar); aceptados 0 de 3. (3) t^* mediana 4 sobre 3 episodios completos, censurada en $B = 4$; por episodio: ep. 1: 4 (sin aceptar), ep. 2: 4 (sin aceptar), ep. 3: 4 (sin aceptar); aceptados 0 de 3. (4) t^* mediana 4 sobre 3 episodios completos, censurada en $B = 4$; por episodio: ep. 1: 4 (sin aceptar), ep. 2: 4 (sin aceptar), ep. 3: 4 (sin aceptar); aceptados 0 de 3. (5) t^* mediana 4 sobre 3 episodios completos, censurada en $B = 4$; por episodio: ep. 1: 4 (sin aceptar), ep. 2: 4 (sin aceptar), ep. 3: 4 (sin aceptar); aceptados 0 de 3. En conjunto, t^* mediana 4 sobre 15 episodios completos.

2. **Distribución de etiquetas**: conteo de cada $\ell \in L$ sobre todos los intentos.

   En esta corrida: Tabla 1: 60 intentos en total.

3. **Razón de deriva**: para V_I, el cociente entre el número de resultados STATEMENT_DRIFT y el de VC_OPEN; para V_G, el cociente entre DISTRACTOR e INVALID_STEP. Mide cuán a menudo el proponente "resuelve" cambiando la pregunta o cayendo en un error de estudiante.

   En esta corrida: V_P no tiene etiqueta de deriva (la instancia la fija el entorno); se reporta el conteo de INVALID_SCHEDULE: 1 de 60 intentos.

4. **Transferencia**: reducción de t^* en el objetivo T_2 cuando el proponente ha sido entrenado (o condicionado con ejemplos aceptados) sobre T_1, frente a partir de cero.

   En esta corrida: No aplica: la memoria de esta corrida recuerda entre episodios del *mismo* objetivo; no es transferencia entre objetivos, y no se midió ninguna.

5. **Comparación entre jueces**: para un mismo método y un mismo proponente, t^* y etiquetas bajo V_G frente a V_I. Es la medida directa de cuánto de la "facilidad" de un juez proviene del trabajo humano incorporado en él.

   En esta corrida: Tabla 2. Los enunciados de V_G y V_I no coinciden, así que la comparación es indirecta.

6. **Costo**: segundos de juez por intento; determina el cuello de botella real.

   En esta corrida: Segundos de juez por intento: media 0,5, mediana 0,5, máximo 0,7; segundos de modelo: media 111,6, mediana 85,6, máximo 1398,8. Suma: 31 s de juez y 6693 s de modelo. Duración desde el inicio hasta el último intento registrado: (1) 17 min 22 s; (2) 1 h 5 min; (3) 19 min 52 s; (4) 15 min 50 s; (5) 16 min 31 s.

etiqueta	(1)	(2)	(3)	(4)	(5)	total
INVALID_SCHEDULE	0	0	1	0	0	1
NOT_IMPROVED	12	12	11	12	12	59
intentos	12	12	12	12	12	60

Table 1: Etiquetas del juez sobre todos los intentos; las columnas siguen la numeración de las corridas en §1.

entorno	juez	proponente	ep.	acept.	B	t^* med.	intentos	s juez	s LLM
`gd_const_n2`	V_I (teorema)	`gpt-6-luna` (high)	2	0	4	4	10	4,9	218,2
`gd_n1`	V_I (teorema)	`gpt-6-luna` (high)	3	0	4	4	12	11,6	252,1
`pep_fval_mu001_n4`	V_P	`gpt-6-astra` (high)	3	3	4	1	4	1,1	134,2
`pep_fval_mu001_n4`*	V_P	`gpt-6-luna` (high)	3	0	4	4	12	0,5	78,6
`pep_fval_mu01_n5`	V_P	`gpt-6-astra` (high)	3	3	4	1	3	0,6	273,2
`pep_fval_mu01_n5`*	V_P	`gpt-6-luna` (high)	3	0	4	4	12	0,5	82,1
`pep_gradnorm_n4`	V_P	`gpt-6-astra` (high)	3	3	4	1	3	0,6	55,0
`pep_gradnorm_n4`*	V_P	`gpt-6-luna` (high)	3	0	4	4	12	0,5	86,3
`pep_gradnorm_n4_neg`	V_P	`gpt-6-astra` (high)	3	3	4	1	3	0,6	83,0
`pep_gradnorm_n4_neg`*	V_P	`gpt-6-luna` (high)	3	0	4	4	12	0,5	98,7
`pep_gradnorm_n6`	V_P	`gpt-6-astra` (high)	3	3	4	1	3	0,6	69,5
`pep_gradnorm_n6`*	V_P	`gpt-6-luna` (high)	3	0	4	4	12	0,6	212,1

Table 2: Corridas del mismo método (pasos de GD) en `runs/` (se ignoran las carpetas que empiezan por "_"), agrupadas por entorno, juez y proponente como en `python -m unirl summary`. "ep." cuenta episodios completos; los segundos son medias por intento evaluado; "intentos" no cuenta los PROVIDER_ERROR (sin respuesta del modelo). *: entornos y proponente de este informe.

	n	μ	criterio	neg.	τ_{ref} (fuente)	mejor τ	mejor r_P	CERTIFIED	acept.	t^* med.
(1)	4	0	$\|\nabla f(x_n)\|^2$	no	0,0169860 (ce)	0,0204082	-0,1835	no	0/3	4
(2)	6	0	$\|\nabla f(x_n)\|^2$	no	0,0072223 (ce)	0,0124995	-0,5485	no	0/3	4
(3)	4	0	$\|\nabla f(x_n)\|^2$	sí	0,0169860 (ce)	0,0182615	-0,0724	no	0/3	4
(4)	4	0,01	$f(x_n) - f^*$	no	0,0295431 (ce)	0,0318308	-0,0746	no	0/3	4
(5)	5	0,1	$f(x_n) - f^*$	no	0,0076055 (ce)	0,0087266	-0,1375	no	0/3	4

Table 3: Por instancia: τ_{ref} y su fuente (`ce`: búsqueda propia de 06 por entropía cruzada; `tabla`: óptimos publicados), el mejor peor caso τ entre los programas válidos (el certificado si lo hay), el mayor r_P registrado (`raw.reward06`), si hubo CERTIFIED, episodios aceptados sobre completos y t^* mediano (censurado en B).

	mejores pasos h (en unidades de $1/L$)
(1)	1,3000, 1,4000, 1,6000, 1,7000
(2)	1,9000, 1,7500, 1,6000, 1,4500, 1,2500, 1,0000
(3)	1,5500, 1,6500, 1,6500, 1,5500
(4)	1,3500, 2,0500, 1,3500, 2,0500
(5)	1,3500, 1,9500, 1,9900, 1,9500, 1,3500

Table 4: Pasos del programa con el mejor τ de cada instancia, redondeados a cuatro decimales.

6 Jerarquía de confianza entre jueces

Los tres jueces aceptan objetos distintos y dejan residuos de confianza distintos. Ordenados de menor a mayor independencia respecto del humano:

juez	qué certifica	en qué reposa la confianza
V_G	validez de una cadena en un grafo dado	el grafo, escrito por el profesor
V_P	una cota numérica de peor caso	el SDP, la certificación racional exacta
V_I	un teorema en el kernel de Isabelle/HOL	el kernel; la adecuación del triple congelado

Ningún juez elimina la confianza; cada uno la desplaza. V_G la desplaza al autor del grafo. V_P la desplaza a la formulación del PEP y a la implementación del certificador. V_I la desplaza a dos lugares que el kernel no puede inspeccionar: la correspondencia entre el triple de Hoare y el enunciado informal que se pretendía probar, y la matemática auxiliar importada. La Observación 2 muestra que incluso lo que el artículo de referencia reporta como "automático" contiene decisiones humanas en esa frontera. El objetivo del proyecto es medir ese residuo, no negarlo.

Residuo en esta corrida: la formulación del PEP de 06 y la implementación de su certificador exacto. En 5 de 5 instancias τ_{ref} viene de nuestra búsqueda (entropía cruzada), no de la

literatura: CERTIFIED significa mejorar nuestra referencia con certificado exacto, no mejorar lo publicado. El *sandbox* protege el estado del juez, no aísla por completo la máquina: el programa aún puede leer archivos.

7 Entornos

sub.	método	objetivo de fase 2	juez	lemas	distr.	cad. mín.
01	bisección	$m_n \to c$, $f(c) = 0$, error $\leq (b-a)/2^{n+1}$	V_G, V_I	21	7	14
02	punto fijo	Banach en $[a, b]$: unicidad, convergencia, cotas	V_G	20	7	13
03	Taylor	resto de Lagrange; convergencia con derivadas acotadas	V_G	20	7	13
04	Newton	convergencia local cuadrática	V_G	18	7	11
05	secante	convergencia local de orden φ	V_G	21	8	13
06*	pasos de GD	cota de peor caso $f(x_n) - f^*$ o $\|\nabla f(x_n)\|^2$ (PEP)	V_P	—	—	—
08	bisección	triple de Hoare de corrección total del programa `bisection`	V_I (programa)	—	—	—
09	pasos de GD	4 teoremas de cota: `gd_const_dt`, `gd_const_n2`, `gd_const_textbook`, `gd_n1`	V_I (teorema)	—	—	—

Table 5: Entornos de `unirl`. En 01–05 los números se recalculan de los grafos (`proof_kb`): "lemas" cuenta todos los pasos, incluidos distractores y QED; "cad. mín." es el cierre de dependencias de QED. Objetivos de V_I disponibles: `bisection` (variante de programa) y 4 cotas de GD (variante de teorema). El punto fijo aún no tiene objetivo formal; Taylor, Newton y secante sólo disponen de juez de grafo. Proponentes: `gpt-6-luna` y `gpt-6-astra`, ambos con esfuerzo `high`, para todos los jueces (corridas en `runs/`: `gpt-6-luna`: 15, `gpt-6-astra`: 7). *: filas de este informe.

8 Experimentos realizados y previstos

1. *Este informe*: `pep_gradnorm_n4` con `gpt-6-luna` (high) (`20260924-060113-gpt-6-luna-high`; terminada; 3 episodios completos). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: NOT_IMPROVED 12; mejor $\tau = 0{,}0204082$ frente a $\tau_{\text{ref}} = 0{,}0169860$.

2. *Este informe*: `pep_gradnorm_n6` con `gpt-6-luna` (high) (`20260924-061836-gpt-6-luna-high`; terminada; 3 episodios completos). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: NOT_IMPROVED 12; mejor $\tau = 0{,}0124995$ frente a $\tau_{\text{ref}} = 0{,}0072223$.

3. *Este informe*: `pep_gradnorm_n4_neg` con `gpt-6-luna` (high) (`20260924-072359-gpt-6-luna-high`; terminada; 3 episodios completos). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: NOT_IMPROVED 11, INVALID_SCHEDULE 1; mejor $\tau = 0{,}0182615$ frente a $\tau_{\text{ref}} = 0{,}0169860$.

4. *Este informe*: `pep_fval_mu001_n4` con `gpt-6-luna` (high) (`20260924-074351-gpt-6-luna-high`; terminada; 3 episodios completos). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: NOT_IMPROVED 12; mejor $\tau = 0{,}0318308$ frente a $\tau_{\text{ref}} = 0{,}0295431$.

5. *Este informe*: `pep_fval_mu01_n5` con `gpt-6-luna` (high) (`20260924-075941-gpt-6-luna-high`; terminada; 3 episodios completos). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: NOT_IMPROVED 12; mejor $\tau = 0{,}0087266$ frente a $\tau_{\text{ref}} = 0{,}0076055$.

6. Relacionada: `gd_const_n2` bajo V_I (teorema) con `gpt-6-luna` (high) (`20260924-073842-gpt-6-luna-high`; **en curso**: 2 episodios completos de 3 previstos al generar este informe). 0 aceptados de 2 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: PROOF_FAILED 10.

7. Relacionada: `gd_n1` bajo V_I (teorema) con `gpt-6-luna` (high) (`20260924-062122-gpt-6-luna-high`). 0 aceptados de 3 episodios completos, t^* mediana 4 ($B = 4$); etiquetas: PROOF_FAILED 8, INVALID_PROPOSAL 4.

8. Relacionada: `pep_fval_mu001_n4` bajo V_P con `gpt-6-astra` (high) (`20260924-061156-gpt-6-astra-high`). 3 aceptados de 3 episodios completos, t^* mediana 1 ($B = 4$); etiquetas: CERTIFIED 3, INVALID_SCHEDULE 1; mejor $\tau = 0{,}0293248$ frente a $\tau_{\text{ref}} = 0{,}0295431$.

9. Relacionada: `pep_fval_mu01_n5` bajo V_P con `gpt-6-astra` (high) (`20260924-062058-gpt-6-astra-high`). 3 aceptados de 3 episodios completos, t^* mediana 1 ($B = 4$); etiquetas: CERTIFIED 3; mejor $\tau = 0{,}0075285$ frente a $\tau_{\text{ref}} = 0{,}0076055$.

10. Relacionada: `pep_gradnorm_n4` bajo V_P con `gpt-6-astra` (high) (`20260924-060127-gpt-6-astra-high`). 3 aceptados de 3 episodios completos, t^* mediana 1 ($B = 4$); etiquetas: CERTIFIED 3; mejor $\tau = 0{,}0169094$ frente a $\tau_{\text{ref}} = 0{,}0169860$.

11. Relacionada: `pep_gradnorm_n4_neg` bajo V_P con `gpt-6-astra` (high) (`20260924-060745-gpt-6-astra-high`). 3 aceptados de 3 episodios completos, t^* mediana 1 ($B = 4$); etiquetas: CERTIFIED 3; mejor $\tau = 0{,}0169094$ frente a $\tau_{\text{ref}} = 0{,}0169860$.

12. Relacionada: `pep_gradnorm_n6` bajo V_P con `gpt-6-astra` (high) (`20260924-060414-gpt-6-astra-high`). 3 aceptados de 3 episodios completos, t^* mediana 1 ($B = 4$); etiquetas: CERTIFIED 3; mejor $\tau = 0{,}0071538$ frente a $\tau_{\text{ref}} = 0{,}0072223$.

13. Prevista: transferencia entre objetivos (métrica 4), no implementada.

Observación 3 (Interpretación)**.** *Esta interpretación la redactó Claude a partir de los registros de las corridas; no es del autor.*

Luna no obtuvo CERTIFIED *en ninguno de los 15 episodios: casi todos sus programas fueron válidos, pero ninguno bajó de* τ_{ref}*. Su mejor peor caso quedó entre un 7,5 % y un 73 % por encima de la referencia según la variante (el peor, norma del gradiente con* $n = 6$*). Sus mejores programas son sucesiones sin paso largo (el mayor de sus mejores pasos es 2,05). Luna sí probó pasos largos, en 10 de sus 59 programas válidos, pero como sucesiones que crecen casi geométricamente hasta pasos de 8 a 17,5, con peores casos cientos o miles de veces por encima de la referencia. Con las mismas instancias y el mismo juez, Astra propuso composiciones con bloques de paso* $\sqrt{2}$ *y un único paso moderadamente largo, entre 2,26 y 2,98, y mejoró la referencia en las cinco variantes. En este juez la diferencia entre modelos parece de conocimiento: saber que los mejores programas conocidos intercalan un paso largo, pero no demasiado, entre bloques de pasos cortos.*

La memoria no cambió el resultado de Luna: le mostró su mejor programa de cada episodio anterior, que no mejoraba la referencia, y con eso no bastó. En la variante con pasos negativos permitidos, Luna no los usó en su mejor programa; su único intento con un paso fuera de rango devolvió un paso del orden de 10^{32} *y el juez lo rechazó por inválido.*

References

Bryant, D., Huerta y Munive, J. J., and Foster, S. (2026). Verifying numerical methods with Isabelle/HOL. v3, 21 Sep 2026; código: github.com/isabelle-utp/Verified_Numerical_Methods.

Das Gupta, S., Van Parys, B. P. G., and Ryu, E. K. (2024). Branch-and-bound performance estimation programming: A unified methodology for constructing optimal optimization methods. Mathematical Programming.

Drori, Y. and Teboulle, M. (2014). Performance of first-order methods for smooth convex minimization: A novel approach. *Mathematical Programming*, 145(1–2):451–482.

Grimmer, B., Shu, K., and Wang, A. L. (2024). Composing optimized stepsize schedules for gradient descent.

Taylor, A. B., Hendrickx, J. M., and Glineur, F. (2017). Smooth strongly convex interpolation and exact worst-case performance of first-order methods. *Mathematical Programming*, 161(1–2):307–345.